

20220507-书&机器学习

1.过程描述

1.1故事

1.2机器学习

简单神经网络的误差反向传播过程

卷积神经网络的误差反向传播过程

2.结果输出

1.过程描述

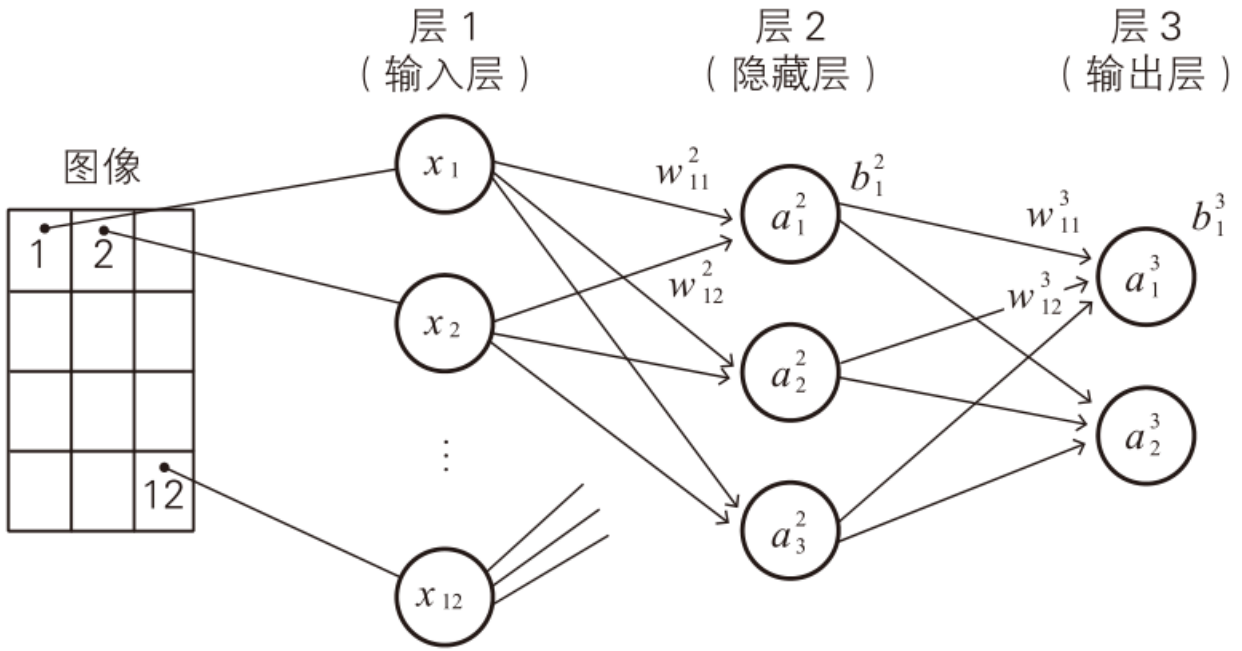
1.1故事

故事是生活的比喻。一个讲故事的人即是一个生活诗人，一个艺术家，将日常生活事件、内在生活和外在生活、梦想和现实转化为一首诗，一首以事件而不是以语言作为韵律的诗——一个长达两个小时的比喻，告诉观众：生活就像是这样！因此，故事必须抽象于生活，提取其精华，但又不能成为生活的抽象化，以致失却了实际生活的原味。故事必须像生活，但又不能一成不变地照搬生活，以致除了市井乡民都能一目了然的生活之外便别无深度和意味。

1.2机器学习

简单神经网络的误差反向传播过程

对于这样的网络：



< 隐藏层 >

$$\left. \begin{aligned} z_1^2 &= w_{11}^2 x_1 + w_{12}^2 x_2 + \dots + w_{112}^2 x_{12} + b_1^2 \\ z_2^2 &= w_{21}^2 x_1 + w_{22}^2 x_2 + \dots + w_{212}^2 x_{12} + b_2^2 \\ z_3^2 &= w_{31}^2 x_1 + w_{32}^2 x_2 + \dots + w_{312}^2 x_{12} + b_3^2 \\ a_i^2 &= a(z_i^2) \quad (i=1, 2, 3) \end{aligned} \right\}$$

< 输出层 >

$$\left. \begin{aligned} z_1^3 &= w_{11}^3 a_1^2 + w_{12}^3 a_2^2 + w_{13}^3 a_3^2 + b_1^3 \\ z_2^3 &= w_{21}^3 a_1^2 + w_{22}^3 a_2^2 + w_{23}^3 a_3^2 + b_2^3 \\ a_i^3 &= a(z_i^3) \quad (i=1, 2) \end{aligned} \right\}$$

要更新网络中的权值与bias，如果暴力求导，将会使得求解过程变得十分复杂。而借助导数的链式法则，可以很轻松地求出误差对于各个权重及bias的偏导，从而实现权值及bias的更新，进而逼近最优。

$$C = \frac{1}{2} \{ (t_1 - a_1^3)^2 + (t_2 - a_2^3)^2 \}$$

$$\begin{aligned} & (\Delta w_{11}^2, \dots, \Delta w_{11}^3, \dots, \Delta b_1^2, \dots, \Delta b_1^3, \dots) \\ &= -\eta \left(\frac{\partial C_T}{\partial w_{11}^2}, \dots, \frac{\partial C_T}{\partial w_{11}^3}, \dots, \frac{\partial C_T}{\partial b_1^2}, \dots, \frac{\partial C_T}{\partial b_1^3}, \dots \right) \end{aligned}$$

在这个过程中，神经节点的误差甚是关键：（可以理解为最后的误差本质上由前面的各个神经元节点的误差构成）


$$\delta_j^l = \frac{\partial C}{\partial z_j^l} \quad (l = 2, 3, \dots)$$

对于所有神经节点：

$$\frac{\partial C}{\partial w_{11}^3} = \frac{\partial C}{\partial z_1^3} \frac{\partial z_1^3}{\partial w_{11}^3}$$

$$\frac{\partial C}{\partial w_{ji}^l} = \delta_j^l a_i^{l-1}, \quad \frac{\partial C}{\partial b_j^l} = \delta_j^l \quad (l = 2, 3, \dots)$$

对于输出层，神经元误差可以很方便地求出来：



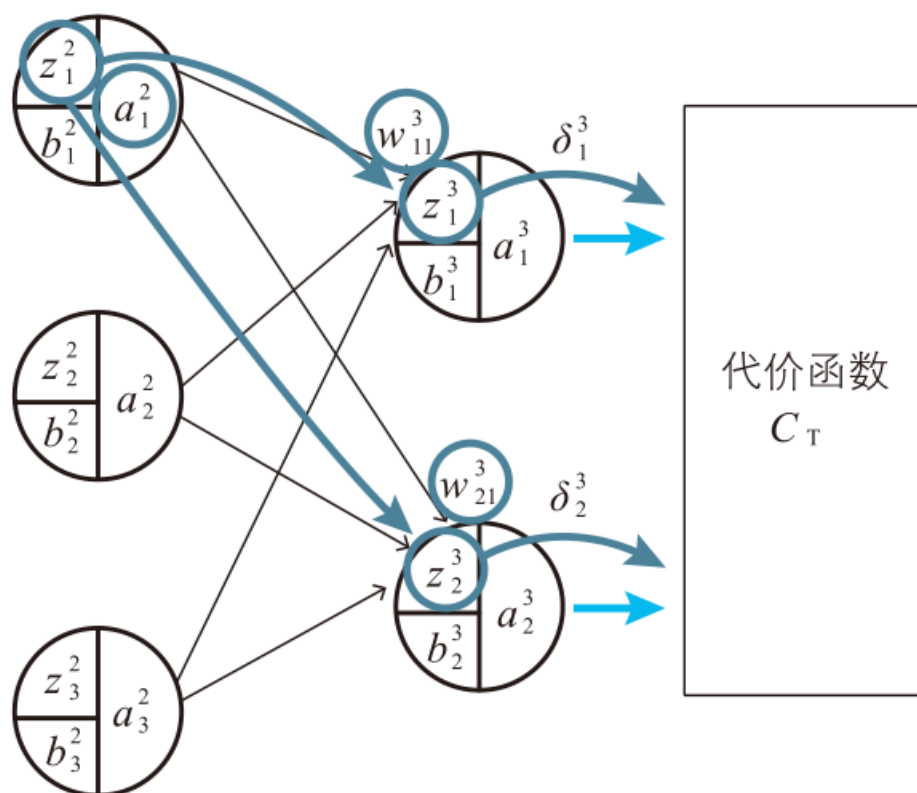
$$\delta_j^3 = \frac{\partial C}{\partial z_j^3} = \frac{\partial C}{\partial a_j^3} \frac{\partial a_j^3}{\partial z_j^3} = \frac{\partial C}{\partial a_j^3} a'(z_j^3)$$

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} a'(z_j^L)$$

对于隐藏层，借助链式规则可以求出神经元误差：

隐藏层(层2)

输出层(层3)



$$\delta_1^2 = \frac{\partial C}{\partial z_1^2} = \frac{\partial C}{\partial z_1^3} \frac{\partial z_1^3}{\partial a_1^2} \frac{\partial a_1^2}{\partial z_1^2} + \frac{\partial C}{\partial z_2^3} \frac{\partial z_2^3}{\partial a_1^2} \frac{\partial a_1^2}{\partial z_1^2}$$


$$\delta_i^2 = (\delta_1^3 w_{1i}^3 + \delta_2^3 w_{2i}^3) a'(z_i^2) \quad (i=1, 2, 3)$$

$$\delta_i^l = \{\delta_1^{l+1} w_{1i}^{l+1} + \delta_2^{l+1} w_{2i}^{l+1} + \cdots + \delta_m^{l+1} w_{mi}^{l+1}\} a'(z_i^l)$$

当两类误差都可以很方便地求解出来时，便可以借助其与误差-权重（bias）的偏导的关系求出相应的更新值。不断重复这个过程便可以逐步逼近最优。

卷积神经网络的误差反向传播过程

对于这样一个卷积神经网络：



对于卷积层：

$$\begin{aligned}
 z_{ij}^{Fk} &= w_{11}^{Fk} x_{ij} + w_{12}^{Fk} x_{ij+1} + w_{13}^{Fk} x_{ij+2} \\
 &\quad + w_{21}^{Fk} x_{i+1j} + w_{22}^{Fk} x_{i+1j+1} + w_{23}^{Fk} x_{i+1j+2} \\
 &\quad + w_{31}^{Fk} x_{i+2j} + w_{32}^{Fk} x_{i+2j+1} + w_{33}^{Fk} x_{i+2j+2} + b^{Fk} \\
 a_{ij}^{Fk} &= a(z_{ij}^{Fk})
 \end{aligned}$$

对于池化层：

$$\begin{aligned}
 z_{ij}^{Pk} &= \text{Max}(a_{2i-12j-1}^{Pk}, a_{2i-12j}^{Pk}, a_{2i2j-1}^{Pk}, a_{2i2j}^{Pk}) \\
 a_{ij}^{Pk} &= z_{ij}^{Pk}
 \end{aligned}$$

对于输出层：

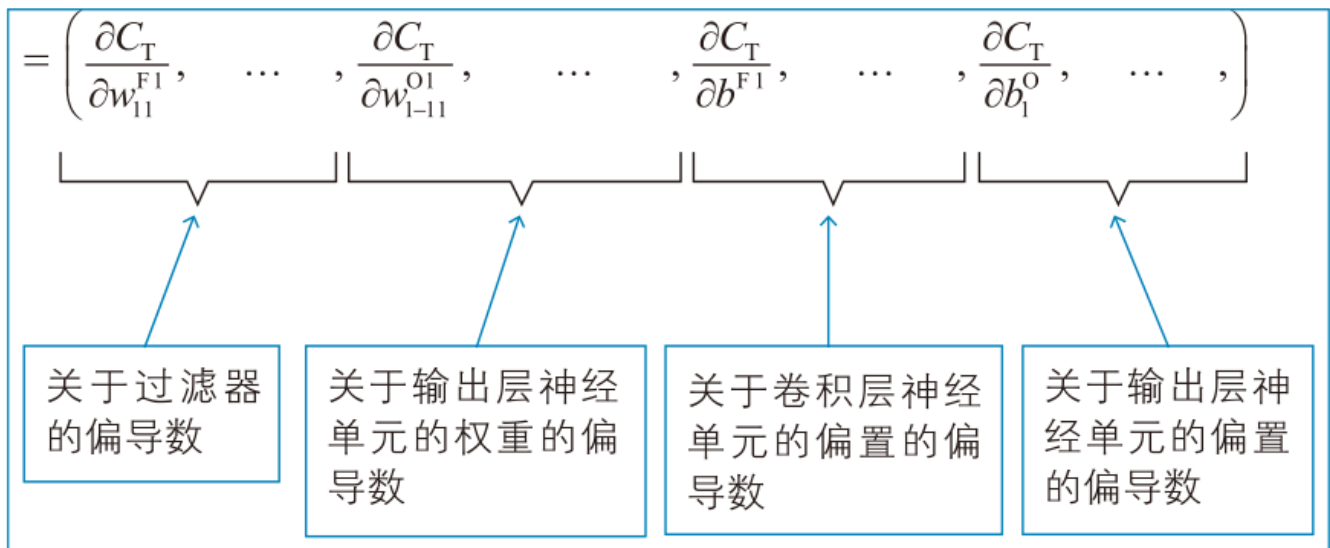
$$\begin{aligned}
z_n^O &= w_{1-11}^{On} a_{11}^{P1} + w_{1-12}^{On} a_{12}^{P1} + w_{1-21}^{On} a_{21}^{P1} + w_{1-22}^{On} a_{22}^{P1} \\
&\quad + w_{2-11}^{On} a_{11}^{P2} + w_{2-12}^{On} a_{12}^{P2} + w_{2-21}^{On} a_{21}^{P2} + w_{2-22}^{On} a_{22}^{P2} \\
&\quad + w_{3-11}^{On} a_{11}^{P3} + w_{3-12}^{On} a_{12}^{P3} + w_{3-21}^{On} a_{21}^{P3} + w_{3-22}^{On} a_{22}^{P3} + b_n^O \\
a_n^O &= a(z_n^O)
\end{aligned}$$

平方误差：

$$C = \frac{1}{2} \{(t_1 - a_1^O)^2 + (t_2 - a_2^O)^2 + (t_3 - a_3^O)^2\}$$

同样地，也是借助于导数的链式法则实现权重以及bias的更新。这个过程比较tricky的是各个上标及下标，很容易混乱。最好还是借助一个简单的网络图形来帮助理清各个符号之前的关系。

最终的目标：




思路跟一般的神经网络比较类似。不同的在于卷积网络的存在共享权值，因此在求偏导时注意到所有与某一自变量相关的所有项。关键的神经元误差：

$$\delta_{ij}^{Fk} = \frac{\partial C}{\partial z_{ij}^{Fk}}, \quad \delta_n^O = \frac{\partial C}{\partial z_n^O}$$

输出层神经元误差与权重更新分量的关系：

$$\frac{\partial C}{\partial w_{2-21}^{O1}} = \frac{\partial C}{\partial z_1^O} \frac{\partial z_1^O}{\partial w_{2-21}^{O1}} = \delta_1^O a_{21}^{P2}$$

$$\frac{\partial C}{\partial b_1^O} = \frac{\partial C}{\partial z_1^O} \frac{\partial z_1^O}{\partial b_1^O} = \delta_1^O$$



$$\frac{\partial C}{\partial w_{k-ij}^{On}} = \delta_n^O a_{ij}^{Pk}, \quad \frac{\partial C}{\partial b_n^O} = \delta_n^O$$

卷积层神经元误差与权重更新分量的关系：

$$z_{11}^{F1} = w_{11}^{F1} x_{11} + w_{12}^{F1} x_{12} + w_{13}^{F1} x_{13} + w_{21}^{F1} x_{21} + w_{22}^{F1} x_{22} + w_{23}^{F1} x_{23} \\ + w_{31}^{F1} x_{31} + w_{32}^{F1} x_{32} + w_{33}^{F1} x_{33} + b^{F1}$$


$$z_{12}^{F1} = w_{11}^{F1} x_{12} + w_{12}^{F1} x_{13} + w_{13}^{F1} x_{14} + w_{21}^{F1} x_{22} + w_{22}^{F1} x_{23} + w_{23}^{F1} x_{24} \\ + w_{31}^{F1} x_{32} + w_{32}^{F1} x_{33} + w_{33}^{F1} x_{34} + b^{F1}$$

.....

$$z_{44}^{F1} = w_{11}^{F1} x_{44} + w_{12}^{F1} x_{45} + w_{13}^{F1} x_{46} + w_{21}^{F1} x_{54} + w_{22}^{F1} x_{55} + w_{23}^{F1} x_{56} \\ + w_{31}^{F1} x_{64} + w_{32}^{F1} x_{65} + w_{33}^{F1} x_{66} + b^{F1}$$

$$\frac{\partial C}{\partial w_{11}^{F1}} = \frac{\partial C}{\partial z_{11}^{F1}} \frac{\partial z_{11}^{F1}}{\partial w_{11}^{F1}} + \frac{\partial C}{\partial z_{12}^{F1}} \frac{\partial z_{12}^{F1}}{\partial w_{11}^{F1}} + \cdots + \frac{\partial C}{\partial z_{44}^{F1}} \frac{\partial z_{44}^{F1}}{\partial w_{11}^{F1}}$$

$$\frac{\partial C}{\partial w_{11}^{F1}} = \delta_{11}^{F1} x_{11} + \delta_{12}^{F1} x_{12} + \cdots + \delta_{44}^{F1} x_{44}$$



$$\frac{\partial C}{\partial w_{ij}^{Fk}} = \delta_{11}^{Fk} x_{ij} + \delta_{12}^{Fk} x_{ij+1} + \cdots + \delta_{44}^{Fk} x_{i+3j+3}$$

$$\frac{\partial C}{\partial b^{Fk}} = \delta_{11}^{Fk} + \delta_{12}^{Fk} + \cdots + \delta_{33}^{Fk} + \cdots + \delta_{44}^{Fk}$$

计算输出层的神经元误差：

$$\delta_n^O = \frac{\partial C}{\partial z_n^O} = \frac{\partial C}{\partial a_n^O} \frac{\partial a_n^O}{\partial z_n^O} = \frac{\partial C}{\partial a_n^O} a'(z_n^O)$$

卷积层的神经元误差与输出层的神经元误差的关系：

$$\begin{aligned} \delta_{11}^{F1} = \frac{\partial C}{\partial z_{11}^{F1}} &= \frac{\partial C}{\partial z_1^O} \frac{\partial z_1^O}{\partial a_{11}^{P1}} \frac{\partial a_{11}^{P1}}{\partial z_{11}^{P1}} \frac{\partial z_{11}^{P1}}{\partial a_{11}^{F1}} \frac{\partial a_{11}^{F1}}{\partial z_{11}^{F1}} \\ &+ \frac{\partial C}{\partial z_2^O} \frac{\partial z_2^O}{\partial a_{11}^{P1}} \frac{\partial a_{11}^{P1}}{\partial z_{11}^{P1}} \frac{\partial z_{11}^{P1}}{\partial a_{11}^{F1}} \frac{\partial a_{11}^{F1}}{\partial z_{11}^{F1}} + \frac{\partial C}{\partial z_3^O} \frac{\partial z_3^O}{\partial a_{11}^{P1}} \frac{\partial a_{11}^{P1}}{\partial z_{11}^{P1}} \frac{\partial z_{11}^{P1}}{\partial a_{11}^{F1}} \frac{\partial a_{11}^{F1}}{\partial z_{11}^{F1}} \end{aligned}$$

$$\delta_{11}^{F1} = \left\{ \frac{\partial C}{\partial z_1^O} \frac{\partial z_1^O}{\partial a_{11}^{P1}} + \frac{\partial C}{\partial z_2^O} \frac{\partial z_2^O}{\partial a_{11}^{P1}} + \frac{\partial C}{\partial z_3^O} \frac{\partial z_3^O}{\partial a_{11}^{P1}} \right\} \frac{\partial a_{11}^{P1}}{\partial z_{11}^{P1}} \frac{\partial z_{11}^{P1}}{\partial a_{11}^{F1}} \frac{\partial a_{11}^{F1}}{\partial z_{11}^{F1}}$$

$$\frac{\partial z_1^O}{\partial a_{11}^{P1}} = w_{1-11}^{O1}, \quad \frac{\partial z_2^O}{\partial a_{11}^{P1}} = w_{1-11}^{O2}, \quad \frac{\partial z_3^O}{\partial a_{11}^{P1}} = w_{1-11}^{O3}$$

$$a_{11}^{P1} = z_{11}^{P1}, \quad z_{11}^{P1} = \text{Max}(a_{11}^{F1}, a_{12}^{F1}, a_{21}^{F1}, a_{22}^{F1})$$

$$\frac{\partial a_{11}^{P1}}{\partial z_{11}^{P1}} = 1$$


$$\frac{\partial z_{11}^{F1}}{\partial a_{11}^{F1}} = \begin{cases} 1 & (\text{在区块中 } a_{11}^{F1} \text{ 是最大时}) \\ 0 & (\text{在区块中 } a_{11}^{F1} \text{ 不是最大时}) \end{cases}$$

$$\delta_{11}^{F1} = \{\delta_1^O w_{1-11}^{O1} + \delta_2^O w_{1-11}^{O2} + \delta_3^O w_{1-11}^{O3}\} \times 1$$

$$\times (\text{当 } a_{11}^{F1} \text{ 在区块中最大时为1, 否则为0}) \times a'(z_{11}^{F1})$$

$$\delta_{34}^{F1} = \{\delta_1^O w_{1-22}^{O1} + \delta_2^O w_{1-22}^{O2} + \delta_3^O w_{1-22}^{O3}\}$$

$$\times (\text{当 } a_{34}^{F1} \text{ 在区块中最大时为1, 否则为0}) \times a'(z_{34}^{F1})$$



$$\delta_{ij}^{Fk} = \{\delta_1^O w_{k-i'j'}^{O1} + \delta_2^O w_{k-i'j'}^{O2} + \delta_3^O w_{k-i'j'}^{O3}\}$$

$$\times (\text{当 } a_{ij}^{Fk} \text{ 在区块中最大时为1, 否则为0}) \times a'(z_{ij}^{Fk})$$

2.结果输出

今天把《深度学习中的数学》一书看完了，不禁感慨，一本好的教材对于激发一个人的学习热情、引领读者进入一个知识领域的重要性。整本书没有任何装腔作势，用最平实朴素的语言，从最基本的数学出发，把神经网络这个看起来就很艰深的话题讲的清清楚楚明明白白，实现了让读者“看得懂”这样一个很多教材都达不到的目标。如果我几年前看到这本书，后续现在对机器学习的认知已经是另一个层次了。明天开始看李牧的《动手学深度学习》，主要用python实现，之前似乎配置环境的时候碰到了一些问题。当这本书看完便要着手用C++设计一个深度学习的API。争取在5月15号前完成这两项任务。之后可能还是得回归到计算机网络的学习，毕竟这个跟工作的相关性比较大。后续可能还有基于QT的软件开发，希望能达到随心所欲开发一些小工具的水平。

时间过得飞快，转眼在宿舍快待一个多月了。回顾这一个多月，学习成果堪忧，只在C++的学习上投入了一点点精力，包括计算机网络、数学、基础大件等的学习全面停滞，C++也远没达到得心应手的地步，实战太少太少。是该好好反思一下自己的学习态度跟学习方法。另外，疫情依旧烦人，学校隔断时间便传出阳性案例，也不知道何年何月才能解封。接下来除了把相关的知识学起来外，更重要的是把体重降下来，以应付好入职体检。